

Разработка интеллектуальной системы анализа патентов химической отрасли для представления данных в структурированном виде

Студент 2-го курса: Кайда Анатолий Сергеевич
Научный руководитель: Глинский Андрей Владимирович

Формулировка проблемы

- ▶ Количество ежегодно публикуемых статей и патентов в химии растет экспоненциально
- ▶ Процесс работы с в патентной и литературной информацией по-прежнему остается в значительной степени ручным
- ▶ Сложность навигации в большом объеме литературы приводит к тому, что важные научные открытия остаются незамеченными в течение длительного времени




Рис. 1: (А) Годовой выпуск научных статей, индексируемых в базе данных WoS. (В) Рост идей, охватываемых статьями, индексируемыми в WoS. Это было определено путем подсчета уникальных заглавных фраз (концепций) в [МФТИ](#) фиксированном количестве статей.

Формулировка проблемы

1. Ananikov V. Top 20 Influential AI-Based Technologies in Chemistry. Chemistry, 2024.

В последние годы набирает обороты «цифровизация» химии.

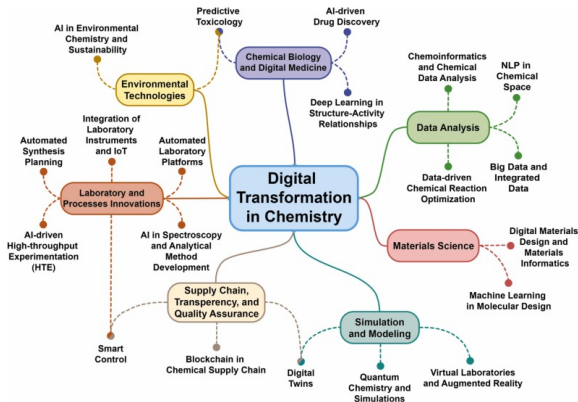


Рис. 2: Связь технологий на основе ИИ с более широкими темами в зависимости от их применения.

Цели и задачи

Цель работы: Создать цифрового «ассистента» на основе большой языковой модели для извлечения структурированных данных из патентной документации

Задачи:

- ▶ Выбрать домен для проведения исследования и провести релевантный патентный поиск и создать БД документов для дальнейшего извлечения информации
- ▶ Провести обзор современных фреймворков и технологий для работы с БЯМ
- ▶ Создать агентов на основе БЯМ способных решать следующие задачи:
 - ▶ Сегментация и фильтрация текста
 - ▶ Классификация текста и выделение информации о синтетических процедурах
 - ▶ Запрос к БЯМ
 - ▶ Формирование датасета

Обзор литературы

2. Ramos M.C., Collison C.J., White A.D. A Review of Large Language Models and Autonomous Agents in Chemistry: arXiv:2407.01603. arXiv, 2024.

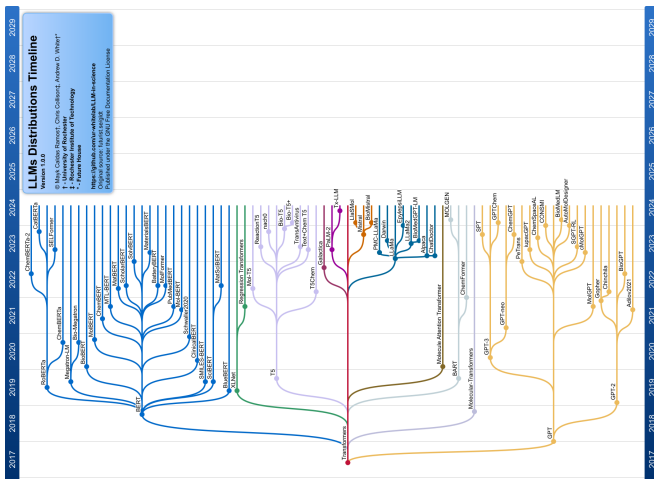


Рис. 4: Иллюстрация хронологической эволюции больших языковых моделей. 

Обзор литературы

3. Lála J. et al. PaperQA: Retrieval-Augmented Generative Agent for Scientific Research: arXiv:2312.07559. arXiv, 2023.

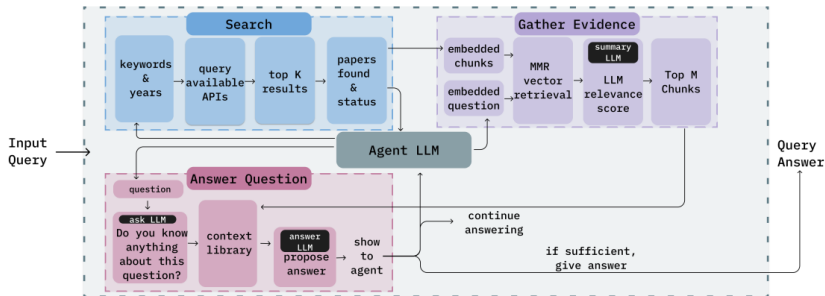


Рис. 5: PaperQA — это агент, который преобразует вопрос в ответ с указанием источников. Агент использует три инструмента: поиск, сбор данных и ответ на вопрос. Инструменты позволяют ему находить и анализировать соответствующие полнотекстовые исследовательские работы, определять конкретные разделы в работе, которые помогают ответить на вопрос, суммировать эти разделы с контекстом вопроса (называемые доказательствами), а затем генерировать ответ на основе доказательств.

Обзор литературы

4. Zheng Z. et al. ChatGPT Chemistry Assistant for Text Mining and Prediction of MOF Synthesis.

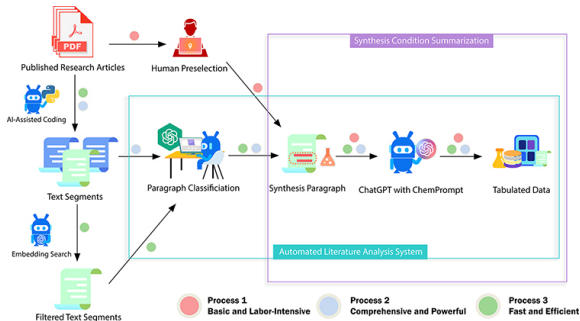


Рис. 6: ChatGPT Chemistry Assistant ChatGPT и ChemPrompt для эффективного анализа текста и обобщения условий синтеза MOF из разнообразного набора опубликованных исследовательских статей.

Текущие результаты и планы

Catalyst type:	PE: ZN on SiO ₂
KEY WORDS:	T/A/C/D: (((((Ziegler-Natta catalyst+) or (silica?supported Ziegler-Natta catalyst+)) and (titanium +chloride)) and gas-phase) and (PE or polyethylene))
RESTRICTION:	ALL
number of documents	
before relevance is determined	There were about 2491 documents (ORBIT)
DATE	Priority date from 01/01/2002
Date of research	13.03.2022
2491	patented inventions
0,5	owned by top 10 players

Таблица 1: результаты поиска по ключевым словам

Текущие результаты и планы

CHINA PETROLEUM & CHEMICAL	3	6	2	2	4	2		27	27	30	18	30	21	11	56	27	22	10	8		
JAPAN POLYPROPYLENE	4	6	6	4	9	18	15	19	15	9	14	23	14	13	6	8	9	7	5	3	
CHINA SINOPEC BEIJING RESEARCH INSTITUTE OF CHEMICALS		2	1	1	1	1		5	14	14	1	26	12	10	51	21	16	2	7		
BOREALIS							6	16	7	10	10	14	14	9	12	19	12	11	19	3	
BASSELL POLYOLEFINE	8	16	9	6	6	3	6	8	2	10	10	9	1	8	8	11	9	7	7	5	
SUMITOMO CHEMICAL	26	30	12	17	6	10	13	14	4	7	3		3			1	1	1		1	
DOW GLOBAL TECHNOLOGIES	10	3	4	10	9	7	10	3	9	3	2	1	2	1	1	4	1	7	6	1	
EXXONMOBIL CHEMICAL PATENTS	2	3	2	23	3		1					3	4	1	10	7	16	2	6	5	
SINOPEC		2	1		1	2		16	8	10	16	2				4	6	1	6		
MITSUI CHEMICALS	5	4	6	5	4	6	2	6	1			2	1	12	1	1	2	3	2		
SABIC GLOBAL TECHNOLOGIES												1	11	11	17	14	2	6	2		
ASAHI KASEI											2	6	1	8	5	14	8	5	1	4	
LOTTE CHEMICAL	1	1				1		2	3		2	1	5	4	6	7	8	9			
LG CHEM			2	3	5	3		7		2	1	1	7	5	8	1			1		
NOVA CHEMICALS			2	1	1	1	1		4	1			4	3	2	13	3	2	2	6	
PRIME POLYMER		2	1	1	2	6	3	5	2	1		2	2	4		1	3	2	5	2	
PETROCHINA				1	1		3	2	4	1	2	7	2	6	3	2	4	5	1		
UNIVATION TECHNOLOGIES	1	11	5	4	1	2	1		1			4	1	1			3	1			
WR GRACE	7	1	1	1		3		3	1	4	2	1	4				3	4	4	1	
BOREALIS TECHNOLOGY	4	3	6	2	5	11	2							1	1						
	2002	2003	2004	2005	2006	2007	2008	2009	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022

Рис. 7: Тепловая карта распределения патентов

Текущие результаты и планы

План работ на третий семестр

- ▶ Создать набор агентов и инструментов для решения задачи извлечения информации на базе одной БЯМ (ChatGPT-3.5Turbo)
- ▶ Собрать небольшой датасет (около 50-100 наблюдений) для оценки эффективности извлечения данных
- ▶ Оценить эффективность обработки данных с помощью метрики F1-score

Список литературы

1. Ananikov V. Top 20 Influential AI-Based Technologies in Chemistry. Chemistry, 2024.
2. Ramos M.C., Collison C.J., White A.D. A Review of Large Language Models and Autonomous Agents in Chemistry: arXiv:2407.01603. arXiv, 2024.
3. Lála J. et al. PaperQA: Retrieval-Augmented Generative Agent for Scientific Research: arXiv:2312.07559. arXiv, 2023.
4. Zheng Z. et al. ChatGPT Chemistry Assistant for Text Mining and Prediction of MOF Synthesis.

